

PROPUESTA DEL PROYECTO

INTEGRANTES:

ISABEL CERÓN SABOGAL
JENSER ORDOÑEZ GARCIA
DANIEL GUERRERO GOMEZ
SONNY ARCOS

**PRESENTADO A:
FREDY JACANAMEJOY**

**INSTITUCION UNIVERSITARIA DEL PUTUMAYO
MOCO-A-PUTUMAYO
2026**

Índice

1.Descripción del Problema de Negocio / Investigación	3
2. Objetivos del Proyecto	3
2.1 Objetivo General	3
2.2 Objetivos Específicos.....	4
3. Alcance del Proyecto	4
3.1 Alcance Temático	4
3.2 Alcance Geográfico.....	5
3.3 Alcance Temporal	5
3.4 Alcance Técnico.....	5
3.5 Exclusiones del Alcance	6
4. Fuentes de Datos	6
4.1 Fuentes Institucionales Primarias.....	6
4.2 Estructura del Dataset Consolidado	7
4.3 Data Warehouse – Esquema Estrella	7
5. Metodología	8
Fase 1 – Extracción, Transformación y Carga (ETL) con KNIME	8
Fase 2 – Modelado Dimensional en SQL Server	8
Fase 3 – Análisis Exploratorio de Datos (EDA) en Power BI.....	8
Fase 4 – Modelado Analítico y Predictivo en RStudio.....	9
Fase 5 – Dashboard Ejecutivo en Power BI.....	9
Resumen de la Pila Tecnológica	10

1.Descripción del Problema de Negocio / Investigación

Colombia enfrenta una deuda histórica en materia habitacional. Décadas de implementación de programas públicos de vivienda de interés social (VIS) y vivienda de interés prioritario (VIP) han generado enormes volúmenes de datos sobre beneficiarios, subsidios, inversión pública y cobertura territorial. Sin embargo, a pesar de la magnitud de estos registros, existe una escasa comprensión integrada de sus patrones, brechas y resultados reales.

El Ministerio de Vivienda, Ciudad y Territorio (MVCT) ha ejecutado durante el período 2003–2026 múltiples programas habitacionales (Mi Casa Ya, Subsidio Familiar de Vivienda Urbano, Casa Gratis/VIPA, Bolsa Desplazados, Semillero de Propietarios, entre otros), cada uno con distintas modalidades de asignación, fuentes de financiación y criterios de focalización. Esta diversidad de esquemas, sumada a la dispersión geográfica de los beneficiarios a lo largo del territorio nacional, dificulta la comprensión holística del impacto real de la política habitacional colombiana.

En el caso específico del departamento de Antioquia, se identifica un problema concreto: los datos de proyectos de déficit habitacional, subsidios de vivienda de interés prioritario y subsidios en modalidad de arrendamiento se encuentran en fuentes dispersas, sin integración analítica que permita identificar qué programas han sido más eficientes, qué subregiones presentan mayores brechas y cómo ha evolucionado la inversión pública en el tiempo.

Esta situación limita la capacidad de los tomadores de decisiones para formular políticas públicas basadas en evidencia, priorizar inversiones territoriales y evaluar el desempeño histórico de los programas habitacionales. La ausencia de una arquitectura de datos integrada y de modelos analíticos aplicados impide transformar los datos brutos en conocimiento accionable.

2. Objetivos del Proyecto

2.1 Objetivo General

Desarrollar una solución de analítica de datos integral que permita descubrir, describir y predecir patrones en los programas de vivienda social del departamento de Antioquia (2003–2026), mediante la construcción de un Data Warehouse, análisis exploratorio en Power BI, modelado predictivo en RStudio y un dashboard ejecutivo, para apoyar la toma de decisiones basadas en evidencia en materia de política habitacional.

2.2 Objetivos Específicos

- Integrar y transformar las fuentes de datos de vivienda social mediante un proceso ETL en KNIME, consolidando información de proyectos de déficit habitacional, subsidios de vivienda prioritaria y subsidios en modalidad de arrendamiento en un único dataset limpio y estructurado.
- Diseñar e implementar un Data Warehouse bajo un esquema estrella en SQL Server, con una tabla de hechos (Hechos_Final_clean) y tres tablas de dimensiones (Programa, Tiempo, Municipio), que sirva como base para el análisis multidimensional.
- Realizar un Análisis Exploratorio de Datos (EDA) en Power BI para identificar patrones de distribución geográfica, tendencias temporales, concentración de inversión por programa y correlaciones entre variables clave.
- Construir modelos analíticos y predictivos en RStudio: un modelo de regresión lineal múltiple para predecir el valor del subsidio asignado y un árbol de decisión CART para clasificar el estado de actividad de los subsidios.
- Desarrollar un dashboard ejecutivo en Power BI que comunique visualmente los hallazgos más relevantes del proyecto, con KPIs, gráficos interactivos y segmentadores que faciliten la exploración de los datos por parte de perfiles no técnicos.
- Identificar brechas y desigualdades en la distribución territorial y programática de los subsidios de vivienda, generando evidencia para la formulación de recomendaciones de política pública.

3. Alcance del Proyecto

3.1 Alcance Temático

El proyecto abarca el análisis de los programas de vivienda de interés social y vivienda de interés prioritario ejecutados en el departamento de Antioquia, Colombia, durante el período comprendido entre 2003 y 2026. Se incluyen tres categorías de datos: proyectos de déficit habitacional, subsidios de vivienda de interés prioritario y subsidios en modalidad de arrendamiento.

3.2 Alcance Geográfico

El análisis se centra en el departamento de Antioquia, desagregado por sus ocho subregiones: Suroeste, Norte, Oriente, Urabá, Occidente, Nordeste, Bajo Cauca y Valle de Aburrá. A nivel nacional, el análisis descriptivo de la presentación de referencia contempla tendencias para Colombia con énfasis en Bogotá D.C., Antioquia y Valle del Cauca como regiones de mayor cobertura.

3.3 Alcance Temporal

Se analizan datos del período 2003–2026, cubriendo más de dos décadas de política habitacional pública en Colombia, lo que permite identificar ciclos históricos, períodos de expansión (2009–2014), contracciones (2015–2019) y recuperación reciente (2020–2026).

3.4 Alcance Técnico

El proyecto comprende las siguientes fases y componentes técnicos:

- Proceso ETL: extracción, transformación y carga de datos en KNIME Analytics Platform.
- Modelado dimensional: diseño e implementación de esquema estrella en SQL Server con 1 tabla de hechos y 3 dimensiones.
- Análisis exploratorio (EDA): construcción de 4 páginas analíticas interactivas en Power BI Desktop con medidas DAX.
- Modelado predictivo: regresión lineal múltiple y árbol de decisión CART en RStudio, con evaluación de métricas (R^2 , AUC, Accuracy, Kappa).

- Dashboard ejecutivo: visualización final en Power BI con KPIs, gráficos de barras, líneas, dispersión y segmentadores interactivos.

3.5 Exclusiones del Alcance

- No se incluyen datos de otros departamentos distintos a Antioquia en el modelado predictivo (aunque sí en la descripción general nacional).
- No se modelan las 478 observaciones sin subsidio asignado (valor_asignado = 0), reservadas para análisis futuros.
- Variables con valor constante (categoriapo = 'Humana') y códigos técnicos sin valor analítico visual son excluidas del dashboard final.
- No se contempla despliegue en producción de los modelos predictivos ni integración con sistemas de información del MVCT.

4. Fuentes de Datos

El proyecto integra datos provenientes de diversas fuentes institucionales y repositorios de datos abiertos relacionados con la política habitacional colombiana:

4.1 Fuentes Institucionales Primarias

Fuente	Descripción	Tipo de Dato
Ministerio de Vivienda, Ciudad y Territorio (MVCT)	Datos de programas de subsidios de vivienda, beneficiarios, estados de postulación y montos asignados	Archivos CSV / Dataset estructurado
Sistema de Información de Vivienda – Antioquia	Proyectos de déficit habitacional, subsidios VIP y	Archivos CSV facilitados

	subsídios de arrendamiento por municipio y subregión	
Datos Abiertos Colombia (datos.gov.co)	Repositorio oficial de datos abiertos del gobierno colombiano con información de programas sociales y habitacionales	Portal web / descarga CSV

4.2 Estructura del Dataset Consolidado

El proceso ETL en KNIME consolidó un dataset final de 1.063 registros y 23 variables, integrando las siguientes categorías de información:

- Variables de identificación: consecutivo, cod_municipio, cod_divipola_mun, cod_divipola_depto.
- Variables de programa: programa, tipoacuerdo, fase, categoriapo.
- Variables temporales: anio_asignacion, fechainicio, fechafin.
- Variables geográficas: municipio, subregion.
- Variables numéricas: hogares, valor_asignado, aportegob, aportemun, aporteotr.
- Variables derivadas: tiene_subsidio (binaria), estado_bin (binaria para modelado).

4.3 Data Warehouse – Esquema Estrella

Los datos consolidados fueron estructurados en un Data Warehouse bajo esquema estrella implementado en SQL Server, con la siguiente arquitectura:

Tabla	Descripción	Variables Clave
Hechos_Final_clean	Tabla de hechos con métricas cuantitativas del programa de vivienda	hogares, valor_asignado, aportegob, aportemun, aporteotr
CatPrograma_clean	Dimensión de programas habitacionales	programa, tipoacuerdo, fase

CatTiempo_clean	Dimensión temporal del análisis	anio_asignacion, fechainicio, fechafin
CatMunicipio_clean	Dimensión geográfica con desagregación municipal y subregional	municipio, subregion, cod_divipola

5. Metodología

El proyecto sigue una metodología de analítica de datos estructurada en cinco fases secuenciales, desde la extracción y preparación de los datos hasta la comunicación visual de hallazgos, con retroalimentación continua entre fases:

Fase 1 – Extracción, Transformación y Carga (ETL) con KNIME

Se utilizó KNIME Analytics Platform para el proceso ETL completo. Las actividades principales incluyeron: ingesta de los archivos CSV fuente, limpieza y estandarización de variables (tratamiento de nulos, normalización de nombres, codificación de categóricas), creación de variables derivadas (tiene_subsidio, estado_bin), y exportación del dataset consolidado en formato CSV limpio para su uso en Power BI y RStudio. El resultado fue un dataset de 1.063 registros y 23 variables.

Fase 2 – Modelado Dimensional en SQL Server

Se diseñó e implementó un esquema estrella en SQL Server con una tabla de hechos central (Hechos_Final_clean) y tres tablas de dimensiones (Programa, Tiempo, Municipio). Este modelo permite consultas multidimensionales eficientes y sirve como fuente de datos para Power BI mediante conexión directa, garantizando consistencia y escalabilidad del análisis.

Fase 3 – Análisis Exploratorio de Datos (EDA) en Power BI

Se construyó un informe de Power BI con cuatro páginas analíticas: (1) Resumen General con KPIs y estado de avance, (2) Análisis Geográfico por subregión y programa, (3) Análisis Temporal con evolución histórica 2003–2025 y correlación hogares-valor ($r \approx 0.986$), y (4) Estado de Subsidios con distribución de estados de postulación. Se crearon cuatro medidas DAX para los indicadores principales (Total Registros, Total Hogares, Total Valor Asignado, Proyectos Con Subsidio).

Fase 4 – Modelado Analítico y Predictivo en RStudio

Se desarrollaron dos modelos en RStudio utilizando el dataset Hechos_Final_clean.csv:

- Modelo 1 – Regresión Lineal Múltiple: variable dependiente valor_asignado, variables predictoras hogares, aportegob, aportemun, aporteotr y anio_asignacion. División train/test 70%/30% con set.seed(123). Resultado: $R^2 = 0.9754$, F-statistic significativo ($p < 2.2e-16$).
- Modelo 2 – Árbol de Decisión CART: variable dependiente estado_bin (1=activo, 0=con novedad), con siete variables predictoras incluyendo programa, anio_asignacion, hogares y subregion. Resultado: Accuracy = 96.59%, Kappa = 0.8974, AUC = 0.9301.

Ambos modelos fueron evaluados con métricas estándar (R^2 , MSE, Accuracy, Kappa, Sensitivity, Specificity, curva ROC) utilizando las librerías rpart, rpart.plot, pROC y caret.

Fase 5 – Dashboard Ejecutivo en Power BI

Se desarrolló un dashboard final de una sola página en Power BI que integra los hallazgos del EDA y el modelado predictivo en un formato ejecutivo. Los componentes incluyen: 4 tarjetas KPI (proyectos totales, inversión total, hogares beneficiados, proyectos con subsidio), gráfico de barras horizontales (inversión por programa), gráfico de líneas (evolución temporal de hogares 2003–2025), gráfico de dispersión (correlación hogares vs. valor_asignado), y tres segmentadores interactivos (subregión, programa, tipo de subsidio). El dashboard está diseñado para usuarios no técnicos y facilita el análisis prescriptivo sobre asignación futura de recursos habitacionales.

Resumen de la Pila Tecnológica

Fase	Herramienta	Propósito	Entregable
ETL	KNIME Analytics Platform	Limpieza e integración de datos	Dataset CSV consolidado (1.063 x 23)
Almacenamiento	SQL Server	Data Warehouse – Esquema Estrella	4 tablas relacionadas
EDA	Power BI Desktop	Análisis exploratorio visual	Informe de 4 páginas con DAX
Modelado	RStudio (R)	Regresión y clasificación	2 modelos con métricas evaluadas
Dashboard	Power BI Desktop	Comunicación ejecutiva	Dashboard interactivo de 1 página