

DICCIONARIO DE DATOS

INTEGRANTES:

ISABEL CERÓN SABOGAL
JENSER ORDOÑEZ
DANIEL GUERRERO GOMEZ
SONNY ARCOS

PRESENTADO A:
FREDY JACANAMEJOY

INSTITUCION UNIVERSITARIA DEL PUTUMAYO
MOCOA-PUTUMAYO
2026

Indice

1. Introducción	3
2. Descripción General de los Datasets.....	4
3. Dataset 1 — Déficit y Mejoramiento de Vivienda.....	5
3.1 Descripción General	5
3.2 Diccionario de Variables	5
4. Dataset 2 — Subsidios de Vivienda Interés Prioritario.....	9
4.1 Descripción General	9
4.2 Diccionario de Variables	9
5. Dataset 3 — Subsidios en Modalidad de Arrendamiento	12
5.1 Descripción General	12
5.2 Diccionario de Variables	12
6. Modelo Entidad-Relación (MER).....	14
6.1 Descripción del Modelo.....	14
6.2 Relaciones del Modelo.....	14
6.3 Diagrama Entidad-Relación.....	15
7. Modelo Estrella (Data Warehouse).....	16
7.1 Descripción del Modelo.....	16
7.2 Tabla de Hechos.....	16
7.3 Tablas de Dimensiones	17
7.4 Diagrama del Modelo Estrella	17
8. Resumen del Proceso de Limpieza.....	18
9. Conclusiones	19

1. Introducción

El presente Diccionario de Datos forma parte del entregable del Punto 2 del Proyecto Final de la asignatura Analítica de Datos. Su propósito es documentar de manera formal y estructurada la naturaleza, composición y características de los conjuntos de datos utilizados en el análisis del déficit habitacional y los programas de subsidios de vivienda en Colombia.

Este documento sirve como referencia técnica para comprender el significado de cada variable, su tipo de dato, sus restricciones y su rol dentro del modelo de datos diseñado para el proyecto. Está alineado con los estándares de documentación de sistemas de información y constituye un insumo fundamental para los procesos de ETL, modelado analítico y visualización ejecutados en las etapas posteriores del proyecto.

2. Descripción General de los Datasets

El proyecto integra tres (3) fuentes de datos de origen gubernamental colombiano, todas de carácter público y relacionadas con la política habitacional del país. A continuación se presenta un resumen consolidado:

ID	Nombre Dataset	Filas	Columnas	Nulos	Descripción
Dataset 1	Déficit y Mejoramiento de Vivienda	809	33	7 (fechas)	Proyectos municipales de vivienda en Antioquia
Dataset 2	Subsidios de Vivienda Interés Prioritario	994	15	0	Sellos de calidad de datos abiertos del gobierno
Dataset 3	Subsidios en Modalidad de Arrendamiento	988	9	0	Subsidios de arrendamiento por municipio

Los datasets fueron obtenidos de fuentes oficiales del gobierno colombiano (datos.gov.co y repositorios departamentales), descargados en formato CSV y sometidos al proceso de limpieza y transformación documentado en el Punto 3 del proyecto.

3. Dataset 1 — Déficit y Mejoramiento de Vivienda

3.1 Descripción General

Contiene información sobre proyectos municipales orientados a reducir el déficit habitacional y mejorar las condiciones de vivienda en los municipios de Antioquia. Incluye datos sobre alcaldes responsables, aportes económicos por fuente, fases de ejecución, población beneficiaria y metas cuantitativas por año.

Registros (filas)	809
Variables (columnas)	33
Registros nulos	7 (columnas fechainicio y fechafin)
Registros duplicados	0
Cobertura geográfica	109 municipios de Antioquia
Período cubierto	2020 – 2023

3.2 Diccionario de Variables

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
consecutivo	INT (int64)	No	809	2020071905	Identificador único del proyecto
tipoacuerdo	VARCHAR (str)	No	3	Ejecucion	Tipo de acuerdo o estado del proyecto
nombrealcaldecomp	VARCHAR (str)	No	109	CARLOS ALBERTO...	Nombre completo del alcalde
correo	VARCHAR (str)	No	107	alcaldia@...gov.co	Correo electrónico institucional del alcalde
municipio	VARCHAR (str)	No	109	Andes	Nombre del municipio beneficiado

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
cod_municipio	INT (int64)	No	109	5034	Código DIVIPOLA del municipio
subregion	VARCHAR (str)	No	8	Suroeste	Subregión a la que pertenece el municipio
cod_subregion	VARCHAR (str)	No	8	SR08	Código de la subregión
nom_plandsllo	VARCHAR (str)	No	115	2020-2023 Alianza...	Nombre del plan de desarrollo municipal
nom_proyecto	VARCHAR (str)	No	806	Fortalecimiento...	Nombre oficial del proyecto de vivienda
pladesarrolloant	VARCHAR (str)	No	1	UNIDOS POR LA VIDA...	Plan de desarrollo departamental Antioquia
compplandsllo	VARCHAR (str)	No	490	Desarrollo del Territorio	Componente del plan de desarrollo
secretariamunicipal	VARCHAR (str)	No	299	Secretaría de Planeación...	Secretaría responsable del proyecto
fase	VARCHAR (str)	No	3	Fase II	Fase de ejecución: Fase I, II o III
desc_proyecto	VARCHAR (str)	No	791	La problemática...	Descripción detallada del proyecto
pobla_afectada	VARCHAR (str)	No	735	43.269	Descripción de la población afectada
pobla_solucion	VARCHAR (str)	No	711	Proyección DANE	Descripción de la solución para la población
categoriapo	VARCHAR (str)	No	1	Humana	Categoría de la población objetivo
nropobla	INT (int64)	No	375	43269	Número de personas en la población objetivo

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
aportegob	INT (int64)	No	204	10000000	Aporte del gobierno nacional en pesos COP
aportemun	INT (int64)	No	171	5000000	Aporte del municipio en pesos COP
aporteotr	INT (int64)	No	48	0	Aporte de otras fuentes en pesos COP
obsevgral	VARCHAR (str)	No	485	No aplica.	Observaciones generales del proyecto
fechainicio	DATE (str)	3	57	2020-08-15	Fecha de inicio del proyecto (YYYY-MM-DD)
fechafin	DATE (str)	4	36	2021-06-30	Fecha de finalización del proyecto (YYYY-MM-DD)
nombrepogramapland	VARCHAR (str)	No	54	Manejo de desastres	Nombre del programa en el plan de desarrollo
nombrepProducto	VARCHAR (str)	No	137	Entidades fortalecidas...	Nombre del producto esperado del proyecto
unidad	VARCHAR (str)	No	16	Número	Unidad de medida del producto
cantidadtotal	INT (int64)	No	94	1	Cantidad total del producto a entregar

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
cantidadanio1	INT (int64)	No	89	0	Cantidad del producto en el año 1
cantidadanio2	INT (int64)	No	26	1	Cantidad del producto en el año 2
cantidadanio3	INT (int64)	No	6	0	Cantidad del producto en el año 3
cantidadanio4	INT (int64)	No	6	0	Cantidad del producto en el año 4

4. Dataset 2 — Subsidios de Vivienda Interés Prioritario

4.1 Descripción General

Contiene el registro de sellos de calidad otorgados a productos de datos abiertos del gobierno colombiano, relacionados con subsidios de vivienda de interés prioritario. Incluye información sobre las entidades certificadas, las categorías de los productos, niveles de calificación y vigencia de los sellos.

Registros (filas)	994 (originalmente 1.000, se eliminaron 6 duplicados)
Variables (columnas)	15
Registros nulos	0
Registros duplicados	0
Cobertura geográfica	18 regiones de Colombia
Período cubierto	2018 – 2024

4.2 Diccionario de Variables

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
id	INT (int64)	No	993	1131	Identificador único del registro de subsidio
año	INT (int64)	No	7	2018	Año de postulación al subsidio
region	VARCHAR (str)	No	18	BOGOTÁ, D. C.	Región geográfica donde se otorgó el subsidio
nombre_entidad	VARCHAR (str)	No	112	DEPTO. ADMVO. FUNCIÓN PÚBLICA	Entidad certificadora

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
					del sello de calidad
nombre_de_producto	VARCHAR (str)	No	860	CARACTERIZACIÓN...	Nombre del producto o dato abierto certificado
url_del_producto	VARCHAR (str)	No	766	https://datos.gov.co/...	URL del producto en el portal de datos abiertos
fecha_de_postulacion	DATETIME (str)	No	993	2018-10-30 09:40:02	Fecha y hora de postulación al sello
fecha_de_certificacion	DATETIME (str)	No	974	2019-12-05 09:25:33	Fecha y hora de certificación del sello
nivel	INT (int64)	No	3	3	Nivel de certificación otorgado (1, 2 o 3)
calificacion	INT (int64)	No	12	0	Calificación obtenida en el proceso de certificación
mes	VARCHAR (str)	No	12	Octubre	Mes de postulación al sello de calidad
activo	INT (int64)	No	1	1	Indica si el sello está activo (1=Sí, 0=No)

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
categoria	VARCHAR (str)	No	5	Gobierno Abierto - Datos Abiertos	Categoría temática del producto certificado
estado	VARCHAR (str)	No	1	OTORGADO	Estado actual del subsidio o sello
fecha_caducidad_sello	DATETIME (str)	No	974	2020-12-04 09:23:54	Fecha y hora de caducidad del sello otorgado

5. Dataset 3 — Subsidios en Modalidad de Arrendamiento

5.1 Descripción General

Contiene información sobre los subsidios de vivienda asignados en modalidad de arrendamiento, discriminados por departamento, municipio y programa. Permite analizar la distribución territorial de los apoyos habitacionales, el número de hogares beneficiados y el valor económico de los subsidios asignados.

Registros (filas)	988 (originalmente 1.000, se eliminaron 12 duplicados)
Variables (columnas)	9
Registros nulos	0
Registros duplicados	0
Cobertura geográfica	30 departamentos, 328 municipios
Período cubierto	Múltiples años de asignación

5.2 Diccionario de Variables

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
departamento	VARCHAR (str)	No	30	VALLE DEL CAUCA	Nombre del departamento donde se asignó el subsidio
codigo_divipola_departamento	INT (int64)	No	30	76	Código DIVIPOLA del departamento
municipio	VARCHAR (str)	No	328	JAMUNDÍ	Nombre del municipio beneficiado con el subsidio

Campo	Tipo de Dato	Nulos	Únicos	Ejemplo	Descripción
codigo_divipola_municipio	INT (int64)	No	329	76364	Código DIVIPOLA del municipio
programa	VARCHAR (str)	No	20	MI CASA YA	Nombre del programa de subsidio de arrendamiento
año_de_asignacion	INT (int64)	No	24	2024	Año en que se asignó el subsidio de arrendamiento
estado_de_postulacion	VARCHAR (str)	No	13	Asignados	Estado actual de la postulación al subsidio
hogares	INT (int64)	No	84	44	Número de hogares beneficiados con el subsidio
valor_asignado	DECIMAL (float64)	No	552	1391000000.0	Valor total del subsidio asignado en pesos COP

6. Modelo Entidad-Relación (MER)

6.1 Descripción del Modelo

El Modelo Entidad-Relación fue diseñado e implementado en SQL Server y refleja la estructura relacional del sistema de información del proyecto. El modelo está compuesto por cinco (5) tablas interrelacionadas que representan las entidades principales del dominio de negocio.

Tabla	Campos Clave	Descripción
Cientes	idCliente (PK), Cliente_Nombre, Cliente_Apellido, Doc_Cliente, Ciudad_Cliente	Almacena los clientes del sistema
Vendedores	idVendedor (PK), Vendedor_Nombre	Registro de vendedores asociados a facturas
Productos	idProducto (PK), Nombre_Producto, Categoria	Catálogo de productos disponibles
Facturas	idFactura (PK), fecha, idCliente (FK), idVendedor (FK)	Cabecera de cada transacción de venta
DetalleFacturas	idDetalle (PK), idFactura (FK), idProducto (FK), cantidad, Precio Unitario, Subtotal	Líneas de detalle de cada factura


6.2 Relaciones del Modelo

Las relaciones entre las entidades son las siguientes:

- Facturas — Clientes: Relación N:1. Una factura pertenece a un único cliente; un cliente puede tener múltiples facturas.
- Facturas — Vendedores: Relación N:1. Una factura es gestionada por un único vendedor; un vendedor puede gestionar múltiples facturas.
- DetalleFacturas — Facturas: Relación N:1. Una factura puede tener múltiples líneas de detalle.
- DetalleFacturas — Productos: Relación N:1. Un producto puede aparecer en múltiples líneas de detalle.
- .

6.3 Diagrama Entidad-Relación

Figura 1. Diagrama Entidad-Relación generado en SQL Server Management Studio



7. Modelo Estrella (Data Warehouse)

7.1 Descripción del Modelo

El Modelo Estrella fue diseñado para soportar el análisis dimensional de los datos del proyecto en Power BI. Está compuesto por una tabla de hechos central (Hechos_Final_clean) y tres (3) tablas de dimensiones que contextualizan las medidas del análisis.

Tabla	Tipo	Campos
Hechos_Final_clean	HECHOS	consecutivo, tipoacuerdo, municipio, cod_municipio, subregion, fase, nropobla, aportegob, aportemun, aporteotr, fechainicio, fechafin, cantidadtotal, departamento, cod_divipola_depto, municipio_subsidio, cod_divipola_mun, programa, anio_asignacion, estado_postulacion, hogares, valor_asignado, tiene_subsidio
CatPrograma_clean	DIMENSIÓN	programa (PK)
CatTiempo_clean	DIMENSIÓN	anio (PK), mes (PK)
CatMunicipio_clean	DIMENSIÓN	cod_divipola_mun (PK), departamento, cod_divipola_depto, municipio

7.2 Tabla de Hechos

La tabla Hechos_Final_clean centraliza las métricas cuantitativas del análisis y se conecta con las tres dimensiones mediante llaves foráneas. Las métricas principales son:

- nropobla: Número de personas de la población objetivo del proyecto.
- aportegob / aportemun / aporteotr: Aportes económicos por fuente de financiamiento en pesos COP.
- cantidadtotal: Cantidad total de productos esperados del proyecto.
- hogares: Número de hogares beneficiados con subsidios de arrendamiento.
- valor_asignado: Valor en pesos COP del subsidio de arrendamiento asignado.

7.3 Tablas de Dimensiones

CatPrograma_clean: Dimensión que cataloga los programas de subsidio de arrendamiento. Clave primaria: programa.

CatTiempo_clean: Dimensión temporal que agrupa los datos por año y mes. Clave primaria compuesta: (anio, mes).

CatMunicipio_clean: Dimensión geográfica que identifica municipios y departamentos mediante códigos DIVIPOLA. Clave primaria: cod_divipola_mun.

7.4 Diagrama del Modelo Estrella




Figura 2. Modelo Estrella implementado en Power BI para análisis dimensional

8. Resumen del Proceso de Limpieza

Los datasets originales fueron sometidos a un proceso de limpieza y transformación (ETL) implementado con la librería pandas de Python. A continuación se resumen las transformaciones aplicadas a cada dataset:

Dataset	Problema Detectado	Transformación Aplicada	Resultado
Dataset 1	Valores nulos en fechainicio (3) y fechafin (4)	Relleno con pd.NaT; conversión a formato DATE	7 nulos tratados
Dataset 1	Columnas de cantidad en float64	Conversión a int64 con .astype('Int64')	5 columnas corregidas
Dataset 1	Encoding incorrecto (latin-1)	Relectura con encoding='latin-1', guardado utf-8-sig	Caracteres especiales restaurados
Dataset 2	6 filas duplicadas	Eliminación con .drop_duplicates()	994 registros únicos
Dataset 2	Columnas con nombres dañados (Ã³, Ã©)	Renombrado con .rename()	15 columnas correctamente nombradas
Dataset 2	id en float64	Conversión a int64	Tipo corregido
Dataset 3	12 filas duplicadas	Eliminación con .drop_duplicates()	988 registros únicos
Dataset 3	Columnas con nombres dañados	Renombrado con .rename()	9 columnas correctamente nombradas

9. Conclusiones

El proceso de levantamiento y documentación del diccionario de datos permitió identificar las siguientes observaciones relevantes para el proyecto:

- Los tres datasets presentaron problemas de encoding provenientes de la fuente original, lo que sugiere que los portales de datos abiertos no siempre garantizan una codificación UTF-8 consistente.
- Los datasets 2 y 3 contenían duplicados, lo que indica la necesidad de aplicar validaciones de unicidad antes de cualquier proceso de migración a base de datos.
- El Dataset 1 es el más complejo estructuralmente (33 columnas), lo que enriquece el análisis exploratorio pero requiere mayor atención en la selección de variables relevantes para el modelo predictivo.
- El Modelo Estrella facilita la consulta analítica en Power BI al reducir la complejidad relacional a una estructura dimensional optimizada para reportes de vivienda y subsidios.
- La combinación de los tres datasets permite realizar análisis cruzados entre el déficit habitacional (Dataset 1), la certificación de datos (Dataset 2) y la asignación de subsidios de arrendamiento (Dataset 3), generando una visión integral de la política habitacional en Colombia.